

Awesome-Micro-Diffusion-Model: 从零开始的迷你扩散模型

张禹阳

yuyangzh@hust.edu.cn

本报告记录在 MNIST 数据集上从零实现并训练迷你扩散模型 (DDPM) 的完整过程。去噪网络为参数量受限 ($\leq 5M$, 实际 1.85M) 的 U-Net, 全部代码仅使用原生 PyTorch 实现, 在纯 CPU 的约束下完成训练, 从标准正态噪声经 ancestral sampling 生成 8×8 样本网格。报告内容: 前向闭式加噪与反向去噪后验的推导、U-Net 与训练设计、EMA 权重指数滑动平均; 两项扩展——基于 DDIM 的不同步数采样 (η 参数化, $\eta = 0$ 时确定性采样) 与基于 classifier-free guidance 的指定数字生成; 以及训练耗时超标 (约 6h 优化至 1h 量级)、 $\eta = 0$ 确定性采样发散 (定位为余弦调度末端 $\hat{x}_0$ 反解的数值放大, 以截断修复) 等工程问题的分析与解决。

Table of Contents

1 实验概述

2 数学原理

2.1 前向加噪：从逐步加噪到一步到位	3
2.2 反向去噪：后验分布与 ancestral sampling	4
2.3 去噪网络 U-Net	4
2.4 EMA 权重指数滑动平均	4
2.5 扩展一：少步采样与 DDIM	5
2.6 扩展二：指定数字生成	6

3 实验结果

3.1 实验设置	6
3.2 损失曲线	7
3.3 样本网格	7
3.4 不同采样步数对比（扩展一）	7
3.5 指定数字采样（扩展二）	8

4 遇到的问题与解决方法

4.1 训练耗时约为预期的 6 倍：参数量估算代替不了算力估算	9
4.2 精简模型样本质量不足：质量与预算的再平衡	9
4.3 $\eta = 0$ 采样全面失效：余弦调度末端的首步发散	10

References

1 实验概述

一位画家，从一幅完工的画开始观察：**前向**过程向这幅画泼五颜六色的颜料，一步步破坏它；**反向**过程从一片狼藉中，一步步去掉泼上去的颜料。扩散模型正是这一直觉的数字化：前向逐步向图像注入高斯噪声，直到变成纯噪声；反向训练一个去噪网络，从纯噪声中一步步把图像还原出来。

本实验在 MNIST 数据集 (LeCun et al. 1998) (训练集 60,000 张、测试集 10,000 张，每张 $28 \times 28 \times 1$) 上从零实现并训练一个 DDPM (Ho, Jain, and Abbeel 2020)，全部代码仅使用原生 PyTorch (Paszke et al. 2019)，不借助 diffusers 等高级库。实验要求与完成情况：

- **前向加噪**：噪声调度（线性/余弦两种），一步到位的闭式加噪；
- **去噪网络**：U-Net（参数量 $\leq 5M$ ，实际 1.85M），以 MSE 预测噪声并训练；
- **反向采样**：ancestral sampling，从纯噪声逐步去噪，输出 8×8 样本网格；
- **约束**：CPU 训练在 2h 水平（本机为 AMD Ryzen7 5800H），支持 CPU/GPU 自动检测；
- **扩展一**：不同采样步数对生成质量与耗时的影响（DDIM 实现）；
- **扩展二**：指定数字采样（条件扩散 + classifier-free guidance）。

2 数学原理

本节按“前向加噪 → 反向去噪 → 去噪网络 → 训练技巧（EMA） → 两项扩展”的顺序给出核心推导。完整推导见项目 README.md，此处为简要分析。

2.1 前向加噪：从逐步加噪到一步到位

原始图像 x_0 是高维空间中的一个向量（MNIST 即 784 维）。总步数 T ，每一步由上一步的图像生成本步的带噪图像：

$$x_t = x_{t-1} \sqrt{1 - \beta_t} + \epsilon_t \sqrt{\beta_t} \quad (1)$$

噪声向量 ϵ_t 的每个元素独立地从 $\mathcal{N}(0, 1)$ 抽样； β_t 是每步的噪声方差，按预先设计的调度变化。本实现支持两种调度：

- **线性调度** (Ho, Jain, and Abbeel 2020)： $\beta_1 = 10^{-4}$ ， $\beta_T = 0.02$ ，中间线性插值；
- **余弦调度** (Nichol and Dhariwal 2021)： $\bar{\alpha}_t = f(t)/f(0)$ ， $f(t) = \cos^2\left(\frac{t/T+s}{1+s} \cdot \frac{\pi}{2}\right)$ ， $s = 0.008$ ， $\beta_t = 1 - \bar{\alpha}_t/\bar{\alpha}_{t-1}$ （截断至 ≤ 0.999 ）。

逐步加噪可以合并。记 $\alpha_t = 1 - \beta_t$ ， $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ ，利用“独立正态分布之和仍为正态、方差相加”的性质递推，得到一步到位的闭式公式：

$$x_t = x_0 \sqrt{\bar{\alpha}_t} + \epsilon \sqrt{1 - \bar{\alpha}_t} \quad (2)$$

训练时无需逐步模拟，对每个样本随机采一个 t 即可直接构造 x_t 。

2.2 反向去噪：后验分布与 ancestral sampling

目标是根据 x_t 和 t 求 x_{t-1} 的分布。在给定 x_0 的条件下， (x_t, x_{t-1}) 服从二维正态分布；计算协方差并利用“二维正态的条件分布仍是正态”，可得后验 $q(x_{t-1}|x_t, x_0) = \mathcal{N}(\tilde{\mu}_t, \tilde{\beta}_t)$ ，其中：

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t; t) \right) \quad \tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t \quad (3)$$

真实的 ϵ 未知，用网络预测 ϵ_θ 代替。去噪公式即为 ancestral sampling 的一步：

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t; t) \right) + z \sqrt{\tilde{\beta}_t} \quad (4)$$

其中第二项 $z \sqrt{\tilde{\beta}_t}$ ($z \sim \mathcal{N}(0, 1)$) 提供随机性， $t = 1$ 时不再加噪声。

2.3 去噪网络 U-Net

U-Net (Ronneberger, Fischer, and Brox 2015) 由编码器、瓶颈、解码器组成，跳跃连接按 channel 维拼接。本项目经 CPU 实测调优后的配置（调优过程见第 4 节）：

Table 1 | U-Net 结构（输入 $[B, 1, 28, 28]$ ，输出同形状预测噪声，参数量 1.85M）

位置	分辨率	通道数	组成
输入卷积	28^2	24	3×3 conv
编码器 L0/L1/L2	$28^2/14^2/7^2$	24/48/96	ResBlock $\times$ 2, MaxPool 降采样
瓶颈	7^2	96	ResBlock $\rightarrow$ 4 头自注意力 $\rightarrow$ ResBlock
解码器 L2/L1/L0	$7^2/14^2/28^2$	96/48/24	最近邻上采样, concat 跳跃连接, ResBlock $\times$ 2
输出层	28^2	1	1×1 conv 恢复通道数

残差块的结构为 Conv1 $\rightarrow$ GroupNorm $\rightarrow$ SiLU $\rightarrow$ Conv2 $\rightarrow$ GroupNorm $\rightarrow$ SiLU，并把输入经跳跃连接加回输出。时间步 t 经正弦嵌入 ($f_i = 10000^{-2i/d}$ ，偶数位 $\sin(tf_i)$ 、奇数位 $\cos(tf_i)$) 加两层 MLP 得到统一的时间向量；每个残差块再拥有专属的两层 MLP，把它投影为本块通道数的 γ (scale) 与 β (shift)，作用于第一个 GroupNorm 之后——时间信息由此注入到每一个残差块。瓶颈处把 $7 \times 7 = 49$ 个像素视为 token，按 channel 切 4 头做自注意力。

2.4 EMA 权重指数滑动平均

训练中参数 θ 的每步更新都带有 batch 抽样的随机性，最后时刻的参数只是抖动轨迹上的一个随机快照。EMA 维护一份影子参数，每步做一次插值：

$$\theta_{ema} \leftarrow \rho \theta_{ema} + (1 - \rho) \theta \quad (5)$$

把递推展开， θ_{ema} 是参数历史轨迹的指数加权平均，有效窗口约 $\frac{1}{1-\rho}$ 步： $\rho = 0.999$ 对应约 1000 步（约 2 个 epoch），窗口内的高频抖动被平均掉，相当于对参数轨迹做低通滤波。影子参数不参与梯度；采样时加载 EMA 权重（DDPM 原文亦如此 (Ho, Jain, and Abbeel 2020)）。

2.5 扩展一：少步采样与 DDIM

ancestral sampling 必须严格走满全部 T 步，推理耗时与 T 成正比；能否不重训、只用 $S \ll T$ 步完成采样？

1. 突破口：训练只约束“边缘分布”。扩散模型的训练损失只约束单点边缘分布 $q(x_t|x_0) = \mathcal{N}(x_0\sqrt{\bar{\alpha}_t}, 1 - \bar{\alpha}_t)$ ——只检查“第 t 步的图长什么样”，至于这张图是从 $t-1$ 步爬楼梯过来的，还是从起点空降过来的，损失函数根本不关心。只要保证边缘分布不变，从 x_T 到 x_0 的“行走路径”就可以重新规划，从而绕开必须走满 T 步的限制。

2. 重新设计路径：非马尔可夫前向过程。DDPM 的前向是马尔可夫链： x_t 只依赖 x_{t-1} ，必须一阶一阶爬楼梯。DDIM (Song, Meng, and Ermon 2021) 构造一族非马尔可夫前向过程，允许 x_t 同时依赖 x_0 与上一步，从而可以直接“跳步”——从 x_{τ_i} 转移到子序列上的 $x_{\tau_{i-1}}$ 。直观理解：DDPM 规定必须爬楼梯；DDIM 说只要到达时窗外的风景（边缘分布）与爬楼梯看到的完全一样，坐电梯直达任意楼层就是合法的。

3. 反向更新的工程构造。先用边缘分布反解出预测的干净图像 $\hat{x}_0$ ；既然 $x_{\tau_{i-1}}$ 必须落在以 $\hat{x}_0$ 为中心、方差为 $1 - \bar{\alpha}_{\tau_{i-1}}$ 的边缘分布上，它的结构就必然长成“原图方向 + 噪声方向”：

$$x_{\tau_{i-1}} = \sqrt{\bar{\alpha}_{\tau_{i-1}}} \hat{x}_0 + c \epsilon_\theta(x_{\tau_i}, \tau_i) + \sigma_i z, \quad \hat{x}_0 = \frac{x_{\tau_i} - \sqrt{1 - \bar{\alpha}_{\tau_i}} \epsilon_\theta}{\sqrt{\bar{\alpha}_{\tau_i}}} \quad (6)$$

其中的噪声不是推导出来的，而是巧妙设计出来的，刻意拆成两股，原因有三：顺应代数结构（ $\hat{x}_0$ 代回后，展开项天然掉出一个与 ϵ_θ 成比例的系数，写成 $c \epsilon_\theta$ 便于合并同类项）；方差预算的“切蛋糕”逻辑——总预算 $1 - \bar{\alpha}_{\tau_{i-1}}$ 固定，手里恰有两股独立噪声来源（历史方向 ϵ_θ 保持轮廓连续，新噪声 z 弥补预测误差、增加多样性），独立噪声的方差具有可加性，正好切分；保持高斯性（独立高斯的线性组合仍是高斯，只需跟踪均值与方差，避免数学复杂化）。灵魂比喻： $c \epsilon_\theta$ 是手里的指南针（确定性引导）， $\sigma_i z$ 是随机迈出的小碎步（随机性探索），两者相加就是“方向引导”与“随机探索”之间最简单的平衡。

4. 系数确定与 η 的调节。由方差预算 $c^2 + \sigma_i^2 = 1 - \bar{\alpha}_{\tau_{i-1}}$ 解出 $c = \sqrt{1 - \bar{\alpha}_{\tau_{i-1}} - \sigma_i^2}$ ：一旦选定 σ_i ， c 被唯一确定，而 σ_i 本身是自由的——这正呼应“训练只约束边缘分布，转移规则不唯一”的观察。以 DDPM 广义后验标准差为基准引入 $\eta \in [0, 1]$ ，令 $\sigma_i = \eta \sigma_i^{DDPM}$ ，代回得统一的 DDIM 反向更新公式：

$$x_{\tau_{i-1}} = \sqrt{\bar{\alpha}_{\tau_{i-1}}} \hat{x}_0 + \sqrt{1 - \bar{\alpha}_{\tau_{i-1}} - \sigma_i^2} \epsilon_\theta(x_{\tau_i}, \tau_i) + \sigma_i z \quad (7)$$

$\eta = 1$ 时整式退化为 DDPM 的 ancestral sampling (子序列取完整时即标准 DDPM 公式); $\eta = 0$ 时 $\sigma_i = 0$, 无新噪声注入, 过程完全确定——相同 x_T 必得相同结果, "implicit" 由此得名。

5. 少步采样为何倾向 $\eta = 0$ 的确定性模式。步数 S 越小, 子序列相邻步的噪声级差越大, $\hat{x}_0$ 的预测误差被放大得越多; $\eta = 1$ 每步还要额外注入新噪声, 相当于在已偏离的路径上再“乱抖一下”, 误差逐级累积, 样本明显模糊; $\eta = 0$ 则完全消除了随机扰动这一误差来源。直观理解: 步子跨得越大 (步数越少), 越要攥紧指南针 ($\eta = 0$), 少瞎蹦跶; 步数足够多 (S 接近 T) 时偶尔掷骰子 ($\eta = 1$) 才不至于跑偏, 此时两者差别不大。需要注意, 这一经典结论在本实验中**并非无条件成立**: 余弦调度下 $\eta = 0$ 采样曾全面失效, 其定位与修复见 4.3 节。

2.6 扩展二：指定数字生成

无条件模型生成哪个数字全凭运气; 希望像给画家下订单一样指定数字 $y \in \{0, \dots, 9\}$ 。标签先经可学习查找表变成向量 $\vec{emb}_y = \text{EmbeddingTable}[y]$, 与时间嵌入同维相加, 模型变为 $\epsilon_\theta(x_t, t, y)$, 而加噪、损失、采样公式全部不变。

只注入条件, 模型的服从往往不够“坚决”。由贝叶斯公式, $\nabla_{x_t} \log p(x_t|y) = \nabla_{x_t} \log p(x_t) + \nabla_{x_t} \log p(y|x_t)$: 条件分布的 score = 无条件 score + 分类器方向, 给后者加权重 w 即可调节条件强度。但不必真的训练分类器 (Ho and Salimans 2022): $\nabla \log p(y|x_t) = \nabla \log p(x_t|y) - \nabla \log p(x_t)$, 右边两项恰是同一网络在有/无条件下的两种输出: 训练时以 10% 概率把标签替换为空标签 $\emptyset$ (embedding 表第 11 行), 同一网络便同时学会两种模式。噪声预测与 score 只相差一个负系数 (Song et al. 2021), 代入得每步实际使用的引导预测:

$$\hat{\epsilon} = \epsilon_\theta(x_t, t, \emptyset) + w [\epsilon_\theta(x_t, t, y) - \epsilon_\theta(x_t, t, \emptyset)] \quad (8)$$

$w = 1$ 退化为普通条件采样; $w > 1$ 条件特征更鲜明 (过大导致失真); $w = 0$ 退化为无条件采样。每步需条件/无条件两次前向, 之后 DDPM/DDIM 公式照常使用。

3 实验结果

3.1 实验设置

Table 2 | 模型与训练超参数

项目	值
模型参数量	1.85M
扩散步数 T	1000
噪声调度	余弦 (本报告结果); 线性 (可切换)
优化器	Adam, lr = 10^{-3}
batch size / epochs	128 / 20
EMA 衰减 ρ	0.999
梯度裁剪	clip_grad_norm = 1.0
标签 dropout	0.1
运行环境	torch 2.14+CPU




Figure 1 | 训练损失曲线（每 epoch 平均 MSE）

3.2 损失曲线

训练共 20 epoch（余弦调度，条件模型），平均 MSE 从首个 epoch 的 0.0855 快速下降到第 5 epoch 的约 0.040，随后进入缓慢收敛的平台期，最终稳定在 **0.0373**。曲线全程单调下降、无异常抖动，表明 $\text{lr} = 10^{-3}$ 与梯度裁剪的配置合适；平台期的缓慢下降主要来自 EMA 之外参数的细微调整，属于小模型在小数据集上的正常形态。

3.3 样本网格

训练结束后从 $\mathcal{N}(0, I)$ 采 64 张纯噪声，走满 1000 步 ancestral sampling，拼成 8×8 网格：

64 张样本中约 55~58 张（约九成）结构完整、可清晰辨认，数字类别分布均匀、笔画风格多样。典型失败形态为个别样本笔画断裂或与背景噪点粘连成团（图中可见 5~6 张），未出现整张纯噪声或模式坍塌（全部生成同一数字）的情况。对比精简配置（1 块/层、无 EMA）时期约 10/64 难辨认的结果，恢复容量并加入 EMA 后质量提升明显。

3.4 不同采样步数对比（扩展一）

实验协议：固定随机种子，使各步数下初始噪声 x_T 完全相同，质量差异只来自步数与 η ；步数取 $S \in \{1000, 200, 100, 50, 20\}$ ，分别用 $\eta = 1$ （DDPM 后验）与 $\eta = 0$ （确定性 DDIM）采样 64 张并记录耗时。

耗时：与步数近似线性（每步一次网络前向，约 100~140ms/步），从 1000 步的 93.9s 降到 20 步的 2.8s，加速约 34 倍； η 不改变每步计算量，两条曲线耗时一致。

质量： $\eta = 1$ 在 1000/200 步质量良好， ≤ 100 步出现明显噪声残留与轮廓模糊，20 步几乎只剩虚影——每步注入的新噪声在少步时逐级累积误差。 $\eta = 0$ （经 4.3 节所述的 $\hat{x}_0$ 截断修复后）表现截然不同：1000 到 20 步的样本几乎无差别，20 步仍清晰可辨，验证了 2.5 节“少步倾向确定性模式”的分析。也就是说，DDIM 在本实验中以 1/50 的步数（20 步、2.8s）达到了与 1000



Figure 2 | 最终无条件权重的 8×8 样本网格 (ancestral sampling, 1000 步, EMA 权重, $\eta = 1$ 不截断)

Table 3 | 不同采样步数的耗时 (64 张, CPU)

步数 S	总耗时 (s)	平均每步 (ms)
1000	93.9	93.9
200	27.8	138.9
100	15.4	154.3
50	7.1	141.9
20	2.8	139.8

步 ancestral sampling (93.9s) 目测相当的质量。

复现命令见项目 README.md 的 Quick Start 一节。

3.5 指定数字采样 (扩展二)

用条件模型分别以 $w = 2.0$ 生成 0–9 各 8 张 (每行一个数字), 并对比不同 guidance 强度的效果:

指定数字采样效果良好: 图 5 中 10 行样本全部命中指定数字, 目测命中率约 100%, 且每行内部保留了笔画粗细、倾斜角度的多样性 (非复制同一模板)。guidance 强度对比 (图 6, 数字 8) 显示: $w = 0$ 退化为无条件采样 (数字混杂); $w = 1$ 已稳定生成 8; $w = 2$ 形态更饱满、一致性更高; $w = 4$ 笔画进一步加粗、个别样本略显夸张, 但未出现失真崩坏。 $w \in [1, 4]$ 均有效, $w = 2.0$ 是条件强度与自然度之间的合适折中。

复现命令见项目 README.md 的 Quick Start 一节。




Figure 3 | $\eta = 1$ 时不同采样步数的样本对比（每行一个步数，相同初始噪声）

4 遇到的问题与解决方法

4.1 训练耗时约为预期的 6 倍：参数量估算代替不了算力估算

现象：初版模型（base 32、每层级 2 残差块、上采样带平滑卷积，3.16M 参数）按“3M 参数很小”预估 0.5~1h 训完，实测每 epoch 约 18 min，20 epoch 需约 6h。

定位：编写 benchmark.py 实测：单步训练约 230 GFLOPs（前向 0.60 GFLOPs/图 $\times$ 3 $\times$ batch 128），CPU 实际吞吐约 100 GFLOPS $\rightarrow$ 2.3 s/步，机器效率正常，瓶颈是纯卷积算力（前向 + 反向占 66% 时间；数据加载仅 1.4%）。MACs 分布显示：解码器三层占 43%（跳跃连接拼接后 $2C \rightarrow C$ 的卷积最贵），两个上采样平滑卷积占 19%，而 28 $\times$ 28 分辨率处一次 3 $\times$ 3 卷积的成本是 7 $\times$ 7 处的 16 倍。

解决：按实测收益排序应用四项优化——channels_last 内存格式（-25% 时间）、base 32 $\rightarrow$ 24（-44% MACs）、2 块 $\rightarrow$ 1 块每层（-29% MACs）、去掉上采样平滑卷积（-19% MACs），epochs 20 $\rightarrow$ 15。单步 2.3s $\rightarrow$ 0.9s，15 epoch 约 40 min 训完。

教训： $\leq 5M$ 约束的是参数量而非算力。小参数模型若把通道堆在高分辨率层，FLOPs 依然巨大；估算训练时间必须分析每层的 $H \times W \times C^2$ 而不是参数总量。

4.2 精简模型样本质量不足：质量与预算的再平衡

现象：为解决耗时问题精简后的 1.23M 参数模型（1 块/层），64 张样本中约 10 张难以辨认。

分析与解决：容量与训练量均不足。在 2h 预算的剩余空间内做三件事：恢复每层级 2 个残差块




Figure 4 | $\eta = 0$ 时不同采样步数的样本对比（每行一个步数，相同初始噪声）

(1.23M $\rightarrow$ 1.85M, 各分辨率容量翻倍); 新增 EMA 权重平均 (每步开销 $< 1\text{ms}$, 对采样稳定性提升最直接); epochs 15 $\rightarrow$ 20。不恢复 base 32 与平滑卷积 (分别 +76%、+19% 算力, 性价比低)。最终配置 20 epoch 全程控制在预算内, 样本质量满足实验要求。

4.3 $\eta = 0$ 采样全面失效：余弦调度末端的首步发散

现象：步数对比实验中, $\eta = 0$ (确定性 DDIM) 在全部步数档位 (含 1000 步) 产出的样本都是无法辨认的噪声团, 而 $\eta = 1$ 完全正常——与”少步时 $\eta = 0$ 更好”的经典预期恰好相反。

定位：对采样轨迹插桩, 逐步记录 $|x|$ 与 $|\hat{x}_0|$ 的量级：

Table 4 | 50 步采样的轨迹量级 (前 3 步与末步, $\max |x| / \max |\hat{x}_0|$)

步	$\eta = 0$		$\eta = 1$	
	$ x $	$ \hat{x}_0 $	$ x $	$ \hat{x}_0 $
第 1 步 ($t = 999$)	3.8	839.9	3.8	839.9
第 2 步 ($t = 979$)	30.0	151.3	24.8	128.4
第 3 步 ($t = 958$)	34.9	89.5	17.5	36.7
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
最末步 ($t = 0$)	26.4	26.1	1.04	1.02

数据范围本应是 $[-1, 1]$, 但 $\eta = 0$ 的 $|x|$ 从第一步起持续发散、全程未恢复; $\eta = 1$ 起点完全相同, 却在两三步内被拉回正常量级。

原因：余弦调度在 $t \rightarrow T$ 时把 $\bar{\alpha}_t$ 压到接近 0 (本模型 $\bar{\alpha}_T \approx 4 \times 10^{-33}$, 而线性调度约 4×10^{-5})。构造 $\hat{x}_0 = (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta) / \sqrt{\bar{\alpha}_t}$ 时要除以 $\sqrt{\bar{\alpha}_T} \approx 6 \times 10^{-17}$ ——网络预测与 x_T 之间的任何微小偏差都被放大到数百倍 ($|\hat{x}_0|$ 达 840)。 $\eta = 0$ 不注入任何新噪声, 误差在确定性轨迹上步步相传、无法自恢复; 而 $\eta = 1$ 在高噪声区的后验方差 $\sigma^2 \approx 1$, 注入的新鲜噪声占主导, 相当于每



Figure 5 | 指定数字采样：0-9 各 8 张，每行一个数字 ($w = 2.0$, EMA 权重)

步”重新洗牌”，一步之内就冲掉了放大的误差。换言之，确定性方法没有随机性做掩护，数值细节会被放大为成败之别；余弦调度把 α 末端压得过低，本就不适合跳步/确定性采样 (Nichol 与 Dhariwal 也指出线性调度更适合少步采样 (Nichol and Dhariwal 2021))。

解决：将 $\hat{x}_0$ 截断到数据范围 $[-1, 1]$ (DDIM 官方实现中的标准细节)，一行改动。修复后 $\eta = 0$ 全程 $|x| \leq 1$ ，且在 20~1000 步间质量几乎不变 (见 4 与 3.4 节分析)。

后续回归与修正：截断上线后， $\eta = 1$ 的 1000 步样本出现了约 13 个孤立亮点 (背景噪点)。用同权重、同种子、仅”是否截断”一个变量的对照实验定位 (孤立亮点计数：截断 13 vs 不截断 1) —— $\eta = 1$ 时注入的噪声本就能冲掉高噪声区的发散，截断反而把模型尚未确定的边界像素提前钉死在 ± 1 ，在低噪声区 σ 变小后冻结为噪点。最终改为仅 $\eta < 1$ 时截断： $\eta = 1$ 恢复不截断 (与 0907 版实现代数等价，质量一致)， $\eta < 1$ 保留截断 (防发散)。修复后 $\eta = 1$ 孤立亮点降回 2， $\eta = 0$ 依然不发散。




Figure 6 | 不同 guidance 强度 $w \in \{0, 1, 2, 4\}$ 的对比 (同一数字、相同初始噪声)

教训：反解公式中“除以接近 0 的量”是数值地雷。随机性采样器的噪声会掩盖这类问题，使其长期潜伏；一旦换用确定性采样器便立即暴露。实现论文公式时，应同步对照官方实现中的工程细节（截断、截位、eps 保护），它们往往不是可有可无的。但工程细节也没有免费的午餐：为确定性场景打的补丁可能伤害随机性场景——修复手段应按机制分场景启用，并用地毯式对照实验（同权重、同种子、单变量）验证。

References

- Ho, Jonathan, Ajay Jain, and Pieter Abbeel (2020). “Denoising Diffusion Probabilistic Models”. In: Proc. of NeurIPS.
- Ho, Jonathan and Tim Salimans (2022). “Classifier-Free Diffusion Guidance”. In: NeurIPS Workshop on Diffusion Models.
- LeCun, Yann, Léon Bottou, Yoshua Bengio, and Patrick Haffner (1998). “Gradient-based learning applied to document recognition”. In: Proceedings of the IEEE 86.11, pp. 2278–2324.
- Nichol, Alexander Quinn and Prafulla Dhariwal (2021). “Improved Denoising Diffusion Probabilistic Models”. In: Proc. of ICML.
- Paszke, Adam, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, et al. (2019). “PyTorch: An Imperative Style, High-Performance Deep Learning Library”. In: Proc. of NeurIPS.
- Ronneberger, Olaf, Philipp Fischer, and Thomas Brox (2015). “U-Net: Convolutional Networks for Biomedical Image Segmentation”. In: Proc. of MICCAI.
- Song, Jiaming, Chenlin Meng, and Stefano Ermon (2021). “Denoising Diffusion Implicit Models”. In: Proc. of ICLR.
- Song, Yang, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole (2021). “Score-Based Generative Modeling through Stochastic Differential Equations”. In: Proc. of ICLR.